

Slovenská technická univerzita
Fakulta informatiky a informačných technológií
Umelá inteligencia

Zadanie 3 - Problém obchodného cestujúceho **B)Tabu search**

Jakub Hrnčár
AIS ID: 110 800, ak. rok 2021/2022

1. Úvod do zadania

Problém obchodného cestujúceho (ďalej TSP) je populárny NP problém. Jeho podstata je hľadanie najlacnejšej Hamiltonovskej kružnice, pričom jeho obtiažnosť spočíva najmä v tom, že nikdy nevieme s istotou povedať, že sme našli najlacnejšiu - vždy môže byť lacnejšia. Pre tento dôvod používame na vypracovanie iba optimalizačné algoritmy, ktoré teoreticky môžu pracovať do nekonečna.

Použitý algoritmus v tomto zadaní sa nazýva Tabu search; je to modifikovaná verzia Hill-climbing algoritmu, takže iba neustále vytvárame nové stavy a porovnávame, či sme vytvorili niečo lepšie.

Zadanie bolo vypracované v jazyku Python 3.9, v prostredí PyCharm Ultimate s hardvérom:

CPU: Intel i3-10100F 4 jadrá 8 vlákien

RAM: 16 GB DDR4 2666 MHz CL 16

2. Stručný opis algoritmu

Celý program sa rozdeľuje do 3 častí: generovanie základného stavu, Tabu search, fitness funkcia.

Generovanie základného stavu

Základný stav je vygenerovaný náhodne; jednotlivé body sa môžu nachádzať na náhodnom mieste v simulovanom 200x200 2D poli, pri čom sa nemôžu sa nachádzať na rovnakom mieste. Stav je reprezentovaný 2D polom, v ktorom sa nachádzajú súradnice každého mesta, pri čom cesta sa tvorí čítaním súradníc zľava doprava:

```
starter = []
while len(starter) != 40:
    new = [random.randint(1, 200), random.randint(1, 200)]
    if new not in starter:
        starter.append(new)
```

Fitness funkcia

Keďže sa nachádzam v 2D poli a potrebujem zistiť priamu vzdialenosť medzi dvoma bodmi a následne tieto vzdialenosti sčítať dokopy. Táto reprezentácia dovoľuje veľmi jednoduché počítanie fitness hodnoty - pracujem s údajmi ako body v karteziánskej sústave a vypočítam veľkosť vektora medzi dvoma susednými bodmi.

```
for i in range(len(current) - 1):
    vector = [current[i + 1][0] - current[i][0], current[i + 1][1]
    - current[i][1]]
    counter += math.sqrt((vector[0]**2) + (vector[1]**2))
```

Tabu search

Pri implementácii som sa riadil týmto pseudokódom:

```
1 sBest ← s0
2 bestCandidate ← s0
3 tabuList ← []
4 tabuList.push(s0)
5 while (not stoppingCondition())
6     sNeighborhood ← getNeighbors(bestCandidate)
7     bestCandidate ← sNeighborhood[0]
8     for (sCandidate in sNeighborhood)
9         if ( (not tabuList.contains(sCandidate)) and (fitness(sCandidate) > fitness(bestCandidate)) )
10             bestCandidate ← sCandidate
11     end
12 end
13 if (fitness(bestCandidate) > fitness(sBest))
14     sBest ← bestCandidate
15 end
16 tabuList.push(bestCandidate)
17 if (tabuList.size > maxTabuSize)
18     tabuList.removeFirst()
19 end
20 end
21 return sBest
```

Je to teda iteratívny algoritmus, ktorý veľmi pripomína algoritmus na hľadanie minima/maxima z údajov. Pri generovaní detí (susedov) jedného stavu používam nasledovný spôsob:

Generujem toľko detí, koľko je aj miest (bodov).

Deti sa generujú výmenou prvého prvku s každým ďalším prvkom.



Posledné dieťa sa vygeneruje výmenou druhého prvku s posledným.



Tabu list je iba jednoduché pole, do ktorého sa vkladajú prvky, ktoré boli vyhodnotené ako Najlepšie z detí (ak Najlepšie neexistuje, tak sa vloží prvý).



3. Testovanie programu



Vždy, keď sa splní podmienka nájdenia lepšieho kandidáta ako je základný kandidát (riadok 9 v pseudokóde), tak sa vloží fitness hodnota do .csv súboru. Na konci testovania tento súbor spracujem v Exceli do grafu.


Keďže sa mestá generujú na náhodných miestach, existuje možnosť, že sa vytvorí pomerne dobrá cesta hneď na začiatku, lebo sa mestá umiestnia na výhodné miesta. Na testovanie som zvolil rôzne hodnoty počtu miest (20, 30, 40) a rôzne hodnoty veľkosti Tabu listu (50, 250, 500). Všetky testy boli spustené pre 10 000 iterácií, čo som zistil že je dostačujúce množstvo pre dané počty miest.











4. Záver

Na väčšine testov vidíme pokles ceny cesty o 40-50%, pričom generovanie je náhodné, takže toto číslo nie je smerodajné; napríklad v poslednom teste sa nepodarilo pri 10 000 iteráciách vylepšiť hodnotu o také významné číslo ako v predošlých prípadoch. Ďalšie závery z testovania sú nasledovné:

- vyrovnanie krivky znamená nájdenie najlacnejšej cesty
- krivka zvykne oscilovať medzi rovnakými hodnotami po nájdení najlacnejšej cesty
- čím je väčší tabu list, tým menej vyrovnaný graf je a vzniká viac oscilácií
- tempo zlepšovania sa postupom iterácií výrazne spomaľuje; na začiatku je veľmi rýchle
- 10 000 iterácií je pre 20, 30, 40 miest dostatočný počet
- čím je väčší tabu list, tým je dlhšie aj vykonávanie programu
- optimalizácia by bola použitie hash tabuľky namiesto poľa v tabu liste
- ďalšia optimalizácia by sa dala vykonať skrz zlacnenie výpočtu vzdialenosti medzi mestami; napríklad pomocou matice susednosti, pričom by sa vzdialenosť nepočítala vždy nanovo